

PBertKla + ML 스택킹 모델 아키텍처

3-Stage Sequential Pipeline · DL Fine-tuning → ML Stacking → Soft-Voting Ensemble




Figure 1. 전체 파이프라인. Stage 1의 transformer 5-fold OOF/평균이 Stage 2 ML 모델들의 메타 피처로 흐른다.

1. 개요

본 모델은 단백질 서열로부터 라이신 락틸레이션(Kla) 부위를 예측하는 3단계 sequential stacking 파이프라인이다. Stage 1에서 ProteinBERT 백본을 5-fold 교차검증으로 파인튜닝해 강한 representation을 얻고, Stage 2에서 그 출력을 메타 피처로 받아 트리 기반 ML 모델 3종을 학습한다. Stage 3에서는 ML 3종의 출력을 soft-voting으로 결합해 최종 예측을 낸다.

2. Stage 1 — ProteinBERT 5-fold 파인튜닝

단백질 서열을 입력으로 받아 Kla 가능성 확률(0~1)을 출력하는 DL 모델 단계. 전체 train CSV를 StratifiedKFold(n_splits=5, shuffle=True, seed=42)로 분할하고 각 fold마다 ProteinBERT를 새로 파인튜닝한다.

2.1 Backbone 모델

- ProteinBERT pretrained checkpoint: epoch 92,400 / sample 23.5M
- Local + Global attention 결합 구조 (Conv-1D + Multi-head attention 6 blocks)
- Sigmoid 분류 head (2-class binary: Kla / Non-Kla)
- Dropout 0.5 (분류 head)

2.2 학습 절차 (각 fold)

Stage	설명	핵심 하이퍼파라미터
A. Frozen warmup	Pretrained transformer freeze, head만 학습	lr=1e-2, frozen=True
B. Full fine-tune	전체 unfreeze, val_loss 기반 early stopping	lr=1e-3, batch=32, seqlen=512, max_epochs=100, patience=15
C. Final long-seq	seqlen 1024로 1 epoch 추가 학습	lr=1e-5, n_final_epochs=1

콜백: ModelCheckpoint(monitor=val_loss, save_best_only), ReduceLROnPlateau(factor=0.25, min_lr=1e-5), EarlyStopping(restore_best_weights=True). 각 fold는 같은 공통 test CSV로 평가되어 fold_k/y_pred.npy로 저장된다.

2.3 Stage 1 산출물

fold_k 디렉토리(k=1..5) 각각에:

- best_fine_tuning_model.h5 — 가중치 (Stage 2의 OOF 생성에 재 활용)
- y_pred.npy — 공통 test set에 대한 예측 (Stage 2의 test 메타 피쳐 재료)
- y_val_pred.npy / val_idx.npy — 자기 fold의 validation 예측 (OOF 조립용)
- Train 전체에 대한 OOF 벡터 → 부모 디렉토리의 oof_pred.npy로 조립

3. Stage 2 — ML Stacking (Transformer OOF 메타)

Stage 1에서 만든 transformer 출력을 메타 피처로 받아, 트리 기반 ML 모델 3종을 학습한다. 본 단계의 핵심은 train과 test 시점의 메타 피처가 모두 transformer 분포를 갖도록 동일한 점이다 (정석 Stacked Generalization).

3.1 ML 입력 피처 구성 (총 422차원)

피처 그룹	차원	출처	비고
AAC (Amino Acid Composition)	20	수기 통계	20개 표준 아미노산 빈도 비율
DPC (Dipeptide Composition)	400	수기 통계	20×20 dipeptide 빈도 비율
Sequence length	1	수기 통계	정수 길이
DL Meta Feature	1	PBertKla 출력	Train: 5-fold OOF / Test: 5-fold avg
합계	422	—	—

3.2 메타 피처의 의미 — Train/Test 분포 일치

- Train 메타 (OOF): 각 train 샘플의 메타 피처를, 그 샘플을 학습에 사용하지 않은 fold에서 얻음. 5-fold이므로 모든 train 샘플이 정확히 한 번씩 "본인을 학습에 안 본 모델"의 예측을 받음. 데이터 누수 없음.
- Test 메타 (5-fold avg): 5개 fold가 모두 학습에 사용하지 않은 test 샘플에 대해 각자 예측 → 5개 예측의 평균. 분산 감소 효과.
- 분포 일관성: 두 단계 모두 "transformer 출력" 분포 → ML이 학습한 결합 규칙이 test에서 그대로 일반화됨.

3.3 ML 모델 3종 + Optuna 튜닝

모델	탐색 하이퍼파라미터	튜닝 설정
LightGBM	learning_rate, max_depth, num_leaves, subsample, colsample_bytree, reg_alpha/lambda	100 trials × 5-fold CV
XGBoost	learning_rate, max_depth, subsample, colsample_bytree, gamma, reg_alpha/lambda	100 trials × 5-fold CV
CatBoost	iterations, learning_rate, depth, l2_leaf_reg, bagging_temperature, border_count	100 trials × 5-fold CV

Optuna TPE 샘플러 (seed=42)로 AUC-ROC를 maximize. 각 trial은 422차원 입력에 대해 5-fold StratifiedKFold CV의 평균 AUC를 평가. 최적 params로 train 전체 다시 학습 후 lgbm_model.txt / xgb_model.json / catboost_model.cbm 저장.

4. Stage 3 — Soft-Voting Ensemble

Stage 2에서 학습한 3종 ML 모델의 예측 확률을 단순 평균하여 최종 확률을 계산하고, 임계값 0.5를 적용해 binary 분류한다.

4.1 수식

$$p = (p_{lgbm} + p_{xgb} + p_{cat}) / 3$$

$$= 1 \text{ (Kla-site) if } p \geq 0.5, \text{ else } 0 \text{ (Non-Kla-site)}$$

4.2 설계 결정 — 왜 단순 평균인가

- 학습 가중치 없음: validation set이 작거나 유사할 때 weighted voting의 가중치가 overfit될 위험. 단순 평균은 편향 없이 robust.
- DL은 ensemble에 직접 포함하지 않음: DL 출력은 Stage 2에서 이미 메타 피처로 흡수되었으므로 별도 포함 시 double-counting. ML 3종이 각자 다른 방식으로 (DL 메타 + sequence) 정보를 결합한 결과를 평균.
- 3 모델의 다양성 가정: LightGBM/XGBoost는 비슷한 boosting 구조이지만 split 알고리즘 차이로 약간의 다양성 제공, CatBoost는 ordered boosting과 categorical handling으로 더 큰 다양성 기여.

5. 추론 시점의 데이터 흐름

단계	입력	처리	출력
1. DL 추론	Test 서열 + 5-fold weight 5개	각 fold weight로 test 추론 → 5개 예측 평균	test 메타 피처 (1차원)
2. Sequence feature 추출	Test 서열	AAC(20) + DPC(400) + length(1)	421차원
3. Concat	421 + 1	단순 hstack	422차원 입력 X
4. ML 추론	X 422차원	lgbm.txt, xgb.json, catboost.cbm 로드 후 predict_proba	p_lgbm, p_xgb, p_cat (각 N차원)
5. Soft voting	3개 확률 벡터	산술 평균	p (N차원)
6. Threshold	p	$\geq 0.5 \rightarrow 1, \text{ else } 0$	최종 binary 예측

6. 핵심 설계 결정 요약

결정 사항	채택	근거
DL backbone	ProteinBERT (epoch 92400) 단백질 도메인 전문 pretrained, contextual embedding이 단순 통계보다 강력	
DL CV 폴드 수	5-fold StratifiedKFold	데이터 크기에 적정. 너무 작으면 분산↑, 너무 크면 학습 오래 걸림
Train 메타 출처	Transformer 5-fold OOF	데이터 누수 없으면서 test와 같은 transformer 분포 보장
Test 메타 출처	Transformer 5-fold 평균	단일 fold cherry-picking 회피, 분산 감소
ML 모델 선택	LightGBM + XGBoost + CatBoost	Tree-based 다양성, Optuna 튜닝 효율성, 학습 속도
Sequence feature	AAC + DPC + length	단순하고 빠름. 향후 ESM/conservation 등으로 교체 가능
Optuna trials	100 × 5-fold CV	수렴에 충분. 50으로 줄여도 비슷한 성능
Ensemble 방식	단순 평균 (soft voting)	weighted voting의 가중치 overfit 위험 회피
분류 임계값	0.5	기본값. 검증셋에서 F1 최대화하는 threshold로 fine-tune 가능

7. 모델 파일 위치 (참조)

산출물	경로
DL 가중치 (fold별)	results/data{N}/fold_k/best_fine_tuning_model.h5
DL OOF 벡터	results/data{N}/oof_pred.npy
DL fold별 test 예측	results/data{N}/fold_k/y_pred.npy
ML 모델	results/ML_output/data{N}_oof/{lgbm_model.txt, xgb_model.json, catboost_model.cbm}
ML 최적 hyperparameters	results/ML_output/data{N}_oof/best_hyperparams.json
내부 test 결과	results/ML_output/data{N}_oof/results_summary.json