

PBertKla + ML 스택킹 파이프라인

변경 전 vs 변경 후 종합 비교 보고서

내부 test, 외부 16샘플 test, DL baseline 모두 포함

문서 정보	
대상 파이프라인	PBertKla 5-fold 파인튜닝 + LightGBM/XGBoost/CatBoost 스택킹
변경 사항	ML train 메타 피쳐: LightGBM-OOF → Transformer-OOF (정석 stacking)
내부 test	각 데이터셋 자체 test split (data1: 1,928 / data2: 2,595 / data3: 5,207)
외부 OOD test	Data/4_infer_new_data/new_data_v1.csv (16 samples, 양성 8 + 음성 8)
변경 전 결과 출처	results/ML_output/data{N}/, paper_figure/roc_curve/newdata_data{N}_ML/
변경 후 결과 출처	results/ML_output/data{N}_oof/, results/Inference_oof/data{N}_newdata/
작성일	2026-04-26

1. 요약 (TL;DR)

기존 파이프라인에서 ML 학습 시점의 메타 피처를 LightGBM OOF에서 Transformer 5-fold OOF로 교체하고, ML 추론 시점의 메타도 단일 fold에서 Transformer 5-fold 평균으로 통일하여 정석 Stacked Generalization을 구현했다. 본 보고서는 이 변경의 실제 효과를 두 가지 평가셋에서 정량 비교한다.

평가셋	변경 전	변경 후	변화
내부 test (n=1928~5207)	ML AUC 0.62~0.91 (모델별 편차 큼)	ML AUC 0.88~0.91 (DL 수준 또는 그 이상으로 안정적)	모든 데이터셋에서 개선
외부 16샘플 OOD	ML AUC 0.45~0.72 (cherry-picked 결과)	ML AUC 0.36~0.52 (정직한 결과)	하락 — 이유는 본문 5장

핵심 메시지: 내부 test에서는 변경 후 모델이 모든 면에서 개선됐다. 외부 16샘플에서는 수치가 하락한 것처럼 보이지만, 이는 변경 전 결과가 fold 선택과 분포 mismatch가 만든 over-optimistic 수치였음이 드러난 것이다. 16샘플 자체가 통계적으로 너무 작고, transformer가 이 OOD 분포에 일반화하지 못하는 근본적 한계가 정직하게 드러났다.

2. 변경 사항 한눈에

항목	변경 전 (Before)	변경 후 (After)
ML 학습 train 메타	LightGBM OOF (sequence features)	Transformer 5-fold OOF
ML 추론 test 메타	Transformer 단일 fold (e.g. fold_2)	Transformer 5-fold 평균
Train·Test 메타 분포	다름 (LGBM vs Transformer)	동일 (Transformer · Transformer)
DL 5-fold 활용	1개 fold만 사용	5개 fold 모두 사용 (OOF + avg)
방법론 분류	비표준 변형	표준 Stacked Generalization
DL 재학습 필요?	—	기존 가중치 재활용 (OOF 생성만 추가)

3. 내부 test 결과 (각 데이터셋의 자체 test CSV)

각 데이터셋의 train CSV로 학습하고, 그 데이터셋의 test CSV로 평가한 결과. test 샘플 수가 충분히 크므로 수치 신뢰도가 높다.

3.1 data1 (n_test = 1928)

모델	변경 전 AUC	변경 후 AUC	변경 전 F1	변경 후 F1
LightGBM	0.6798	0.8825	0.6173	0.8101
XGBoost	0.6183	0.8832	0.5665	0.8099
CatBoost	0.8714	0.8828	0.7947	0.8097
Ensemble	0.7332	0.8831	0.6212	0.8111
— DL 5-fold avg —	—	0.8827	—	—

3.2 data2 (n_test = 2595)

모델	변경 전 AUC	변경 후 AUC	변경 전 F1	변경 후 F1
LightGBM	0.7390	0.8870	0.6579	0.7892
XGBoost	0.7419	0.8870	0.6603	0.7903
CatBoost	0.7219	0.8897	0.6405	0.7910
Ensemble	0.7336	0.8884	0.6506	0.7906
— DL 5-fold avg —	—	0.8881	—	—

3.3 data3 (n_test = 5207)

모델	변경 전 AUC	변경 후 AUC	변경 전 F1	변경 후 F1
LightGBM	0.9028	0.9103	0.8259	0.8315
XGBoost	0.9031	0.9110	0.8257	0.8284
CatBoost	0.9110	0.9130	0.8329	0.8301
Ensemble	0.9080	0.9126	0.8312	0.8314
— DL 5-fold avg —	—	0.9063	—	—

관찰: 변경 후 모든 ML 모델이 DL 5-fold 평균 AUC와 비슷하거나 더 높은 수준으로 수렴한다. 특히 data1에서는 LGBM/XGB가 변경 전 0.62~0.68 → 변경 후 0.88로 큰 폭 개선됐다. 이는 train-test 메타 분포 일치로 ML이 학습한 결합 규칙이 비로소 test에서 제대로 일반화됨을 의미한다.

4. 외부 16샘플 OOD test (Data/4_infer_new_data/new_data_v1.csv)

양성 8개 (ALDOA_230, ALDOA2_322, cGAS_131, TEAD1_108, YAP_90, CPT1_457, CPT2_458, PDHA1_336) + 음성 8개 (NonKla1~8). 학습 데이터와 분포가 다른 외부 셋.

4.1 data1

DL per-fold AUC: 0.484 / 0.406 / 0.391 / 0.422 / 0.391

DL 5-fold avg AUC: 0.438 (acc 0.375)

모델	변경 전 AUC	변경 후 AUC	변경 전 F1 / Acc	변경 후 F1 / Acc
LightGBM	0.7188	0.4531	— / 0.562	0.444 / 0.375
XGBoost	0.6719	0.4844	— / 0.500	0.444 / 0.375
CatBoost	0.4531	0.4375	— / 0.438	0.444 / 0.375
Ensemble	0.6250	0.4844	— / 0.500	0.444 / 0.375

4.2 data2

DL per-fold AUC: 0.375 / 0.359 / 0.438 / 0.406 / 0.516

DL 5-fold avg AUC: 0.391 (acc 0.500)

data2는 변경 전 외부 16샘플 결과가 없습니다.

모델	변경 전 AUC	변경 후 AUC	변경 전 F1 / Acc	변경 후 F1 / Acc
LightGBM	—	0.3906	—	0.471 / 0.438
XGBoost	—	0.3594	—	0.444 / 0.375
CatBoost	—	0.4062	—	0.444 / 0.375
Ensemble	—	0.3906	—	0.444 / 0.375

4.3 data3

DL per-fold AUC: 0.406 / 0.578 / 0.594 / 0.562 / 0.406

DL 5-fold avg AUC: 0.406 (acc 0.500)

모델	변경 전 AUC	변경 후 AUC	변경 전 F1 / Acc	변경 후 F1 / Acc
LightGBM	0.5625	0.4688	— / 0.625	0.267 / 0.312
XGBoost	0.5781	0.4688	— / 0.625	0.267 / 0.312
CatBoost	0.5938	0.5156	— / 0.625	0.556 / 0.500
Ensemble	0.5781	0.4688	— / 0.688	0.267 / 0.312

5. 외부 16샘플에서 수치가 낮아진 이유 (분석)

5.1 Fold cherry-picking이 사라짐

변경 전 파이프라인은 5개 fold 중 한 개(예: data3 fold_2)만 inference에 사용했다. 16샘플 OOD test에 대한 per-fold AUC를 보면:

데이터셋	fold 1	fold 2	fold 3	fold 4	fold 5	5-fold 평균
data1	0.484	0.406	0.391	0.422	0.391	0.438
data2	0.375	0.359	0.438	0.406	0.516	0.391
data3	0.406	0.578	0.594	0.562	0.406	0.406

data3에서 fold_2 = 0.578이 가장 좋은 fold 중 하나였다. 변경 전 추론은 우연히 이 lucky fold를 선택했고, 변경 후 5-fold 평균(0.406)은 다른 약한 fold들과 섞여 낮아진다. 또한 16개라는 작은 표본에서 fold 간 예측이 다른 샘플에서 엇갈려 평균 자체의 AUC가 per-fold AUC보다 낮아지는 현상도 발생했다 (data3: 평균 0.406 < per-fold 최댓값 0.594).

5.2 Transformer가 이 OOD set에 일반화하지 않음

data1 transformer는 모든 5개 fold에서 AUC < 0.5로 사실상 분류 능력이 없다. data2도 5개 중 1개만 0.5를 넘는다. 이는 학습 데이터의 분포와 16샘플 new_data_v1의 분포가 매우 다르다는 강력한 신호다. 변경 후 ML 모델은 이 OOD-에 약한 transformer 신호를 train 메타로 받아 학습했으므로, ML도 OOD에서 약해진다.

5.3 변경 전이 우연히 OOD에서 더 잘 보였던 이유

변경 전 파이프라인은 train 메타로 LightGBM(sequence-only) OOF를 사용했다. ML 모델은 학습 시점에 "transformer 분포"가 아닌 "sequence 통계로부터 도출된 확률 분포"를 보고 학습했다. 그런데 OOD인 16샘플에서는 transformer가 제 역할을 못 하므로, ML이 transformer 신호에 덜 의존하는 변경 전 구조가 우연히 더 robust해 보인 것이다. 즉, 변경 전 0.719라는 수치는 "올바른 stacking이 아니어서" 우연히 더 좋게 나온 케이스다.

- 변경 전 data1 LightGBM AUC 0.719: ML이 transformer를 학습 시 안 봐서 OOD에서도 transformer의 잘못된 신호에 끌려가지 않음 (happy accident).
- 변경 후 data1 LightGBM AUC 0.453: ML이 transformer를 정직하게 메타로 받음 → transformer가 잘못된 OOD에서 함께 잘못됨.
- 어느 쪽이 "진짜" 모델 능력인가? 변경 후가 정확한 측정이고, 변경 전이 우연이 만든 over-estimate.

5.4 16샘플은 통계적으로 너무 작음

양성 8 + 음성 8개의 16샘플 평가는 한 샘플 차이가 AUC $1/64 = 0.0156$, accuracy $1/16 = 6.25\%$ 를 움직인다. 두 모델 비교에 의미를 부여하려면 차이가 적어도 0.05 이상 나야 하는데, 본 보고서의 거의 모든 비교는 그 이하 또는 그 경계에 있다. 어떤 결과도 "통계적으로 유의"하다고 주장할 수 없다.

6. 결론 및 권고

6.1 본 변경의 평가

정식 Stacked Generalization 적용은 다음 두 가지 효과를 모두 달성했다:

- 내부 test에서 명백한 개선: ML 모델들이 DL baseline 수준 또는 그 이상으로 수렴 (data1 LightGBM 0.62→0.88). 이는 train-test 메타 분포 일치로 ML이 학습한 결합 규칙이 비로소 test에서도 의미를 가지게 된 결과.
- 외부 16샘플에서 정직한 성능 노출: 이전의 0.72같은 수치는 fold cherry-picking + 분포 mismatch가 만든 over-estimate. 변경 후 수치가 모델의 진짜 OOD 일반화 능력 (즉, 현재로선 부족함) 을 보여줌. 이는 결함이 아니라 진단 정보.

6.2 논문 보고를 위한 권고

- 주요 결과는 내부 test로 보고. data1/2/3 모두 AUC 0.88~0.91 수준으로 충분히 강한 결과. 변경 전 vs 후 비교를 ablation으로 함께 표시.
- 외부 16샘플 결과는 "OOD evaluation"으로 명시적 라벨링. 수치가 낮음을 honest하게 보고하고, 학습 데이터와 분포 차이가 원인임을 설명.
- 외부 평가셋 확장 강력 권고. 16샘플은 통계적 유의성을 주장할 수 없는 크기. 수백 샘플 이상의 외부 검증셋(다른 단백질 family, 다른 PTM database)을 확보해야 paper review에서 신뢰성 있는 일반화 능력 주장 가능.
- 다음 개선 방향: sequence feature를 transformer와 직교한 것 (ESM/ProtT5 embedding, conservation, structure) 으로 교체하면 ML이 transformer가 놓치는 신호를 보충해 OOD에서도 robust해질 가능성.